

논문 2021-58-3-8

특권 정보를 이용하는 딥러닝 모델을 통한 폐렴 검출

(Deep Learning Under Privileged Information for Pneumonia Detection)

고 명 섭*, 정 병 창**, 김 대 검**, 한 철*

(Myeongseob Ko, ByeongChang Jeong, Daegyeom Kim, and Cheol E. Han[©])

요 약

최근 컴퓨터 비전분야에선 딥러닝의 발달과 함께 이미지 분류 임무에 대한 성능이 급격한 발전을 이루고 있다. 의학 분야에서는 이러한 분류 임무가 여러 종류의 질병을 검출하고 진단하는 데 널리 이용되어 왔다. 본 논문에서는 기존의 이미지 분류를 위해 많이 사용되고 있는 딥러닝 네트워크에 특권 정보를 추가적으로 이용하여 폐렴을 검출하는 방법을 제안한다. 특권 정보는 이미지 내에서 분류 임무와 직접적으로 관련된 영역으로, 본 연구에서는 이미지 내 폐 영역으로 설정하였다. 이와 같은 특권 정보는 근래에 많이 활용되는 내재적 주의집중(implicit attention)의 역할을 함으로써 모델로 하여금 분류 임무와 직접적인 관련이 있는 영역에 집중하도록 도와준다. 본 연구에서는 파라미터가 공유된 VGG-16 모델을 두 개 사용하였는데, 이 중 한 네트워크에는 주 정보인 이미지 자체를 제공하고, 또 하나의 네트워크는 정보 병목, 가우시안 드롭아웃, 리파라미터라이제이션 기법을 이용하여 특권 정보를 제공하였다. 원본 데이터 셋보다 작은 다양한 크기의 데이터 셋을 특권 정보를 제공하였을 때와 제공하지 않았을 때를 비교하였다. 특권정보를 제공하였을 때, 테스트 정확도와 F1점수가 모두 향상되었는데, 데이터셋이 작을수록 특권정보로 인한 성능향상의 폭이 커졌다 (1,000장의 이미지를 사용했을 때는 테스트 정확도 3.5%, F1 점수 0.0285만큼 향상, 100장의 이미지를 사용했을 때는 테스트 정확도 3%, F1 점수 0.0173만큼 향상, 75장의 이미지를 사용했을 때는 테스트 정확도 16.72%, F1 점수 0.0629만큼 향상). 또한 특권 정보를 활용할 경우 모델의 판단에 기준이 된 영역을 활성화 맵을 통해 제시함으로써 해석 가능성을 보여주었다.

Abstract

In a recent computer vision society, there has been an rapid improvement in the performance of image classification tasks along with the development of deep learning technology. In the medical field, these classification techniques have been widely exploited to detect and diagnose several types of diseases. In this paper, we propose a method to detect pneumonia by additionally providing predetermined privileged information with off-the-shelf deep learning networks based on Learning Under Privileged Information (LUPI) framework. The privileged information is a designated area within an image, and can serve as implicit attention, encouraging the model to focus on the area directly related to the task, and thus may improve the classification performance. As an example, in this paper, we designated lung areas as our privileged information. Our proposed model consists of two shared VGG-16 models; one is for processing main information, image itself, and the other is for processing privileged information through information bottleneck, Gaussian dropout, and reparameterization trick. We provided various sized datasets but smaller than the original dataset by resampling it and compared model performances with and without privileged information. Our experiment showed that privileged information improves the test accuracy and F1 score, and the performance gain by the privileged information remarkably increases as the size of dataset gets smaller: increasing test accuracy and F1 score respectively by 3.5% and 0.0285 with 1000 training images, by 3% and 0.0173 with 100 training images, and by 16.72% and 0.0629 with 75 training images. We also demonstrated that our model can be interpretable through the activation maps of our model with the privileged information.

Keywords : deep learning, privileged information, pneumonia detection

*정회원, **비회원 고려대학교 과학기술대학 전자 및 정보공학과

(Department of Electronics and Information Engineering, Korea University)

©Corresponding Author(E-mail : cheolhan@korea.ac.kr)

※ 이 연구는 보건복지부의 재원으로 한국보건산업진흥원(KHIDI)의 국가치매극복기술개발 사업(HI19C0645)의 지원을 받아 진행되었습니다.

Received ; November 11, 2020

Revised ; January 4, 2021

Accepted ; March 8, 2021

I. 서 론

급격한 딥러닝의 발전과 함께 의학 분야에서 피부 질환^[1], 유방암^[2], 뇌 종양^[3, 4] 등 여러 질병을 검출하기 위한 노력이 꾸준히 증가되어 왔다. 이와 같은 질병의 분류나 검출에는 다양한 종류의 신경망이 활용되어 왔다. 하지만, 활성화 지도(activation map)를 보면 실제 진단에 있어 의학적으로 신뢰할만한 영역보다는 이미지의 다양한 영역을 통해 질병을 진단하고 검출하고 있다 (Fig. 1. 참고). 이는 실제 의학 분야의 전문가에게는 신뢰하지 못할 결과일 수 있으며 이에 본 연구에서는 우리가 찾고자 하는 목표에 초점이 맞춰진 정보를 특권 정보(privileged information)로 활용하여 모델을 학습한다. 이를 통해 기계 학습에 있어 우리가 원하는 영역에 더 초점을 맞출 수 있도록 하며, 이는 적은 데이터로도 기존의 데이터를 활용하여 훈련한 모델과 유사하거나 더 좋은 성능을 내는 결과를 만들 수 있다. 이와 같은 LUPI 프레임워크는 이미지넷 데이터셋^[5]에 대한 물체 분류 문제에 적용되었으며^[6], 본 연구에서는 LUPI 프레임워크를 폐렴 진단을 위해 활용하였으며 이를 통해 의학 분야에 대한 확장 가능성을 보여주었다.

본 연구의 기여는 1) 특권정보에 기반한 모델학습(Learning under privileged information LUPI) 프레임워크를 의학 데이터(폐렴 진단)에 접목했다는 점에 있다. 더 많은 데이터를 사용하여 학습하였을 때 더 일반화되고(generalizable) 굳건한(robust) 예측모델이 생성된다는 것은 자명하나, 의학 데이터는 일반 이미지 데이터와는 달리 방대한 양의 데이터를 모으기 쉽지 않다. 예를 들어, 단순한 MNIST dataset를 보더라도 이미지 데이터는 수만 장의 샘플을 쉽게 얻을 수 있지만, 폐렴 분류를 위해 본 연구에서 활용한 공개된 데이터는 수천 장의 샘플 밖에 없다. 상대적으로 부족한 데이터로 더 높은 그리고 신뢰할 수 있는 성능을 보여주기 위해서는 LUPI 프레임워크와 같은 모델이 필요하다. 또한 의학 분야는 특히 단순한 수치의 성능 향상 뿐 아니라 딥러닝 모델이 의학적으로 의미가 있는 영역을 바라보며 학습하거나, 모델의 예측 결과가 설명가능(explainable)하기를 희망한다. 이런 점에서 LUPI 프레임워크는 의학 분야의 전문가가 인지하는 중요한 정보를 학습에 활용할 수 있도록 해줄 수 있다. 2) 본 연구에 활용된 방법에 대한 검증에 위해 기존의 데이터에 특권 정보를 추가하여 우리에게 맞게 데이터셋을 구성하여 비교 분석하였으며, 3) 실험을 통해 특권 정보를 활용할 때 더 높은 정확도

와 F1 점수를 제시할 뿐만 아니라 4) 해석 가능한 모델을 구축할 수 있다는 점을 보였다.



그림 1. VGG-16 모델로부터 얻은 폐렴 검출 결과: (좌) 입력 영상, (우) 활성화 지도

Fig. 1. Pneumonia detection results from VGG-16: (left) input image, (right) its activation map.

II. 본 론

1. 특권 정보에 기반한 모델 학습(LUPI)

사람에게 있어서 효율적인 선생님은 단지 정답만을 제공하는 것을 넘어서 부가적인 설명을 함께 제공함으로써 학생들이 더 빠르게 특정 임무를 학습할 수 있도록 한다. 기계 학습에 있어서도 기존의 튜플(tuples)을 학습에 활용하는 $\{(x_i, y_i)\}_{i=1}^n$ 것을 넘어 특권 정보가 포함된 세 가지의 정보(triplets)를 $\{(x_i, x_i^*, y_i)\}_{i=1}^n$ 모델 학습에 활용할 수 있다. 여기서 활용되는 특권 정보에 테스트 단계에서는 접근할 수 없다. 이는 앞서 제시된 예제에 비유해보면 정답과 선생님의 부가적인 설명을 통해 학생에 대한 학습은 이루어지지만, 시험단계에서는 선생님에 의한 정보가 포함될 수 없는 것과 같다^[6]. 이를 특권 정보에 기반한 학습(Learning Under Privileged Information, LUPI)이라 하며 [7]에서 소개되었다.

특권 정보를 이 연구^[7]에서는 서포트 벡터 머신(Support Vector Machine, SVM)에서 자료가 잘못 분류된 정도를 나타내는 느슨한 변수(slack variable)를 추정하는데 사용했다. 또한, 컴퓨터 비전^[8], 군집화^[9], 메트릭 학습^[10] 연구에도 확장되어 활용되었다. 하지만 이러한 방법들은 최대 마진 학습(max-margin learning)에 기반하며, 최근에 급격하게 성장하고 있는 합성곱 신경망(Convolutional Neural Networks, CNNs)에 응용되기 어렵다는 한계점을 갖는다.

합성곱 신경망에서는, 미리 잘 학습된 큰 모델의 지식을 작은 모델에 활용하는 증류(distillation)의 개념이

도입되면서^[11], 이런 개념과 특권 정보의 유사성에 착안하여 LUPI 프레임워크에 통합되어 활용되기 시작했다^[12]. 다중-모달(multi-modal) 연구에서는^[13] 분류 기법을 통해 이미 학습된 모델에서 증류한 정보를 목표 모델에 활용하는 방법을 보여줬다. 이외에도 다중-임무 학습(multi-task learning) 또한 특권 정보를 활용할 수 있는 방안이지만, 특권 정보를 추정하기 위해 부가적인 임무에 대한 학습을 진행하는 것이 전체적인 학습 성능을 저하시킬 수 있다는 한계점이 있다.

분류하고자 하는 물체의 경계 정보를 활용하면 좀 더 쉽고 직관적으로 특권 정보를 학습에 활용할 수 있다. 본 연구에서는 X-ray 이미지에서 폐 영역을 수작업으로 지정하였다. 폐 영역을 바운딩박스(bounding box)로 표시하고, 이를 특권 정보로 하여 이를 주요 네트워크의 드롭아웃(dropout)^[14]의 분산을 추정하는데 활용한다. 따라서, 본 연구에서는 기존 딥러닝 연구에서 정규화 방법으로 많이 활용되는 베르누이 드롭아웃(Bernoulli dropout)을 활용하지 않고 가우시안 드롭아웃(Gaussian dropout)을 활용한다. 또한, 서로 다른 정보들의(x_i, x_i^*) 최소한이지만 충분한 표현을 학습하기 위해 정보 병목(Information Bottleneck)^[15]을 사용된다.

2. 알고리즘




그림 2. 모델 구조. 주 정보와 특권 정보가 각각 합성곱층을 통과하고, 완전 연결 층에서 특권 정보는 드롭아웃의 분산 역할을 함.

Fig. 2. Overall architecture. Main information(x) and privileged information(x^*) go through convolutional layers and fully connected layers, and privileged information serves as the variance of dropout in fully connected layers.

Fig. 2.은 본 연구에서 활용하는 방법에 대한 전반적인 모델 구조를 보여준다. 기존의 기계 학습 문제가 (X, Y) 공간에서 정의되었다면, LUPI 프레임워크에서는 특권 정보가 추가되어 (X, X^*, Y) 공간에서 정의된다. 따라서, 우리는 데이터 샘플을 식 (1)에 정의된 바와 같은 데이터 분포로부터 얻게 된다.

$$x_i, x_i^*, y_i \sim p(x, x^*, y) \quad (1)$$

이에 따라 우리는 식 (2)와 같은 최적화 문제를 해결하는 것을 목표로 하며, 여기서 $z(x; \mathbf{w})$ 는 $\mathbf{w}$ 라는 파라미터에 대한 함수로써, $z(x; \mathbf{w})$ 는 인풋 x 로부터 얻어지는 함수 값을 나타낸다.

$$\min_{\mathbf{w}} E_{x, y \sim p(x, y)} [l(y, z(x; \mathbf{w}))] \quad (2)$$

여기서 함수 l 은 손실 함수를 나타내고, $l(y, z(x; \mathbf{w}))$ 는 인풋 x 와 함수 $z(x; \mathbf{w})$ 로부터 예측된 값이 실제 값 y 와 가지는 차이 값을 말한다. 결국 식 (2)를 통해 우리는 차이 값을 최소화하는 학습 파라미터 $\mathbf{w}$ 를 찾을 수 있다.

앞서 설명되었듯이, 본 연구는 특권 정보를 추가로 사용하기 때문에 식 (2)는 식 (3)의 최적화 문제로 다시 정의되며, 식 (2)와 같은 문제로 귀결시켜 합성곱 신경망을 활용하기 위해 식 (4)와 같이 x^* 에 대한 marginalization이 필요하다.

$$\min_{\mathbf{w}} E_{x, x^*, y \sim p(x, x^*, y)} [l(y, z^a(x, x^*; \mathbf{w}))] \quad (3)$$

$$z(x; \mathbf{w}) = E_{x^* \sim p(x^*|x)} [z^a(x, x^*; \mathbf{w})] \quad (4)$$

여기서 분포 $p(x^*|x)$ 를 모르기 때문에 이 기댓값이 다루기 힘들어지는 문제가 발생하고 때문에, 이를 다루기 쉬운 형태로 매개변수적 집단(parametric family)에 기반하여 다시 정의해준다.

식 (5)를 보면, 식 (4)의 marginalization이 우리가 알고 있는 주요 정보에 대한 값 z^k 와, 특권 정보를 통해 얻어진 값 z^* 에 의해 정의되는 확률 함수(stochastic function) N 와의 Hadamard 곱($\odot$)의 형태로 나타낼 수 있게 된다.

$$z^a(x, x^*; \mathbf{w}) = z^k(x; \mathbf{w}^k) \odot N(1, z^*(x^*, \mathbf{w}^*)) \quad (5)$$

따라서, 식 (4)의 marginalization은 $z(x; \mathbf{w}) = z^k(x; \mathbf{w}^k)$ 으로 보여 질 수 있다. 여기서 주요 정보 x 에 대한 함수 z^k 와 특권 정보 x^* 에 대한 함수 z^* 에 대한 파라미터를 학습하기 위해 정보 병목을 활용하게 된다.

정보 병목의 목적은 최대한 압축되지만 중요한 정보가 보존된 표현을 만들어내는 것이다. 이런 목적을 염두에 두고, 우리의 두 정보를 바라보면 γ 가 x 와 x^* 의 결합된 표현이며 $\gamma = z^a(x, x^*; \mathbf{w})$ 로 정의되고, 식 (6)과 같이 정보병목의 라그랑지언(Lagrangian)을 얻을 수 있다.

$$L = H(y|\gamma) + \beta I(x, x^*|\gamma) \quad (6)$$

여기서 각각의 항목들은 다음 식 (7)~(8)과 같이 정의된다.

$$I(x, x^* | \gamma) = E_{x, x^* \sim p(x, x^*)} [KL(p_w(\gamma | x, x^*) || p_w(\gamma))] \quad (7)$$

$$H(y | \gamma) \simeq E_{x, x^*, y \sim p} [E_{\gamma \sim p_w(\gamma | x, x^*)} [-\log_{p_w} (y | \gamma)]] \quad (8)$$

여기서 p_w 는 파라미터 $\mathbf{w}$ 와 함께 계산된 분포를 의미한다. 위 식들의 의미를 보면 실제 (x_i, x_i^*) 를 가장 잘 나타낼 수 있는 결합 분포 $p_w(\gamma)$ 와 우리가 얻은 값 $p_w(\gamma | x, x^*)$ 의 차이인 쿨백-라이블러 발산(Kullback-Leibler divergence)이 최소화 될 수 있도록 하는 압축된 표현을 만들것자 한다. 여기서 쿨백-라이블러 발산은^[16], 식 (9)와 같이 표현될 수 있으며;

$$KL(p_w(\gamma | x, x^*) || p_w(\gamma)) \sim \|\log z^*(x^*; \mathbf{w}^*)\| \quad (9)$$

최종적인 최적화 문제는 식 (10)과 같이 크로스 엔트로피 손실(cross-entropy loss)와 정규화 항을 이용하여 정의된다(식의 전반적인 유도는 [6]을 참조).

$$\min_w \frac{1}{n} \sum_{i=1}^n E_{\gamma \sim p_w(\gamma | x, x^*)} [\log p(y_i | \gamma)] + \beta \|\log z^*(x_i^*; \mathbf{w}^*)\| \quad (10)$$

III. 실험

본 연구에서 x 는 이미지, x^* 는 물체의 위치를 포함한 이미지, 그리고 y 는 라벨을 나타낸다. x 와 x^* 은 공유된 합성곱 층(convolutional layer)을 통과하게 되며 이 층들은 VGG-네트워크에 기반한다^[17]. x^* 에서 얻어진 특징 벡터(feature vector)를 리파라미터라이즈(reparameterize)^[18]하여, 결과로 얻어진 값을 가우시안 드롭아웃의 분산으로 활용한다. 이는 x 를 통해 얻어진 특징 벡터의 드롭아웃 역할을 하며, 쿨백-라이블러 발산을 손실함수의 정규항으로 활용함으로써, x 와 x^* 의 결합 표현을 가장 잘 표현할 수 있는 모델의 파라미터를 찾아간다.

본 연구는 PyTorch를 기반으로 수행하였으며, 초기의 학습률은 1.0×10^{-4} 이고, ADAM 최적화 함수^[19]를 사용하였다. 가중치 초기화는^[20]를 적용하였으며, 실험에 활용된 GPU 장비는 Geforce GTX 1080Ti, RAM 16G이다. 배치 사이즈는 8로 설정했다.

1. 데이터셋

우리는 폐렴 데이터 셋을 실험에 활용하였으며, 특권 정보가 특권 정보를 사용하지 않을 때에 비해 폐렴과 정상을 구분하는 데 있어 정확도와 F1 점수에 어떤 영향을 미치며, 결국 효율성 면에서 어떤 결과를 야기하는지 보여줄 것이다. 기존의 데이터 셋은 5, 863장의 X-ray images로 구성되며 이는 폐렴과 정상인의 두 가지 카테고리 나뉘어진다. 이 영상들은 광저우의 Guangzhou Women and Children's Medical Center에서 1-5세 사이의 소아과 환자로부터 얻어졌다. 또한 모든 방사선 사진들은 저품질과 판독할 수 없는 사진들을 제거하는 과정을 거쳤으며, 정상인과 폐렴환자는 두 명의 전문의에 의해 판독되었다^[21]. 기존의 불균형한 데이터 사이즈를 균일하게 해주기 위해 정상인 경우와 폐렴인 경우를 각각 1,000개씩 훈련용으로 무작위 추출하였으며 (기존 데이터는 정상: 1341, 폐렴: 3875), 검증 데이터는 훈련 데이터의 10%를 사용하였다. 전체 데이터 셋의 크기에 따라 테스트 데이터의 크기를 10%-20% 비율로 정한다면 훈련데이터가 100장 혹은 75장인 실험에서는 매우 적은 테스트 데이터를 사용하게 되고, 이는 테스트 데이터를 구성하는데 편향(bias)을 일으킬 수 있어 테스트 정확도의 신뢰성을 떨어트릴 수 있게 된다. 따라서 이를 방지하기 훈련데이터가 1000장일 때, 100장일 때, 75장일 때 모두 테스트 데이터의 크기를 400장으로 유지했다. 본 실험의 목적인 특권 정보가 폐렴 분류 학습에 미치는 효율성과 정확성을 관찰하기 위해 데이터 수에 따라 세 가지 분류([1000], [100], [75])로 나누어 실험을 수행하였으며, 각각은 1개의 클래스당 훈련데이터 수를 의미한다.

2. 실험결과

가. 실험결과1: 학습 성능

Fig. 3.를 보면, 특권 정보를 활용한 모델에서 안정적인 학습이 이루어지고 있으며, 특권 정보를 활용한 모델에서 더 높은 검증 정확도를 기록한 것을 확인할 수 있다. 학습은 100번의 에포크 값을 가지고 수행했으며, 이 값은 각 손실 값과 정확도가 포화되는 지점이다.

Fig. 4.는 특권 정보 유무에 따른 활성화 맵을 보여준다. 특권 정보가 있을 때 (w/ P.I) 정상인 경우와 폐렴일 때 모두 폐 영역에 집중적으로 빨간색이 나타나며, 이는 모델이 분류에서 해당 부분에 근거했다는 의미이고, 따라서 더 해석 가능한 결과를 제시했다고 보인다.

반면 특권 정보를 사용하지 않는 경우 정상인 경우와 폐렴일 때 모두 폐부분보다는 다른 영역에 초점을 맞춘 것을 확인할 수 있다. 이 그림은 우리가 제안하는 모델이 같은 양의 데이터를 사용할 때 더 해석 가능한 결과를 도출할 수 있다는 점을 보여준다.




그림 3. 특권 정보가 있는 모델로부터 얻은 훈련 결과와 (좌) 특권 정보가 없는 모델로부터 얻은 훈련 결과 (우). 노란색, 초록색, 빨간색, 파란색 선들은 각각 훈련 정확도, 검증 정확도, 검증 손실, 훈련 손실을 나타냄. 특권 정보가 있는 경우 모델의 가장 높은 검증 정확도는 0.97이며 특권 정보가 없는 모델의 가장 높은 검증 정확도는 0.965임

Fig. 3. Training results from models with privileged information (left) and without privileged information (right). The yellow, green, red, and blue lines indicate training accuracy, validation accuracy, validation loss and training loss respectively. The highest validation accuracy of the model with privileged information is 0.97 and the highest validation accuracy of the model without privileged information is 0.965.




그림 4. 실험 결과. P.I. 는 특권 정보를 나타냄. 특권 정보가 있을 때에 대한 활성화 지도가 그림 4의 상단에 있으며 특권 정보가 없는 경우에 대한 활성화 지도가 그림 4의 하단에 있음. 두 경우 모두, 특권 정보를 활용했을 때 더 해석 가능한 결과를 보여줌

Fig. 4. Experimental results. P.I. denotes Privileged information. The upper part shows the activation maps with privileged information and the bottom part shows the activation maps without privileged information. Both cases, normal and pneumonia show interpretable results when using privileged information.

나. 실험결과2: 훈련데이터 크기에 따른 성능

본 연구에서는 클래스당 1000장의 훈련데이터 에서부터 100장, 75장까지 데이터 수를 줄여보고, 특권정보가 가지는 효율성을 찾고자 하였다. Table 1에서 보면 알 수 있듯이, 각 실험에서 특권 정보를 활용한 경우 더 높은 테스트 정확도를 보여주었다. 특권 정보를 활용하지 않을 때와 활용할 때, 학습데이터의 크기가 1000장일 때는 3.5%, 100장일 때는 3%, 75장일 때는 16.72%의 테스트 정확도에 차이가 있었다. 또한, 오진율을 줄이기 위해 의학 데이터에서는 F1 점수를 같이 관찰할 필요가 있기에 F1 점수를 같이 제시했다. F1 점수 역시 각 실험에서 특권 정보가 있을 때 더 좋은 값을 보여주었다. F1-score의 차이를 보면, 학습데이터의 크기가 1000장 일 때는 0.0285, 100장 일 때는 0.0173이지만, 학습데이터의 크기가 75장 일 때에는 그 차이가 0.0629으로 크게 벌어진다. 이 표는 우리가 제안하는 모델이 같은 양의 데이터를 사용할 때 특권 정보를 활용할 경우 더 높은 성능의 결과를 도출할 수 있다는 것을 보여주며, 더 나아가 데이터 셋의 크기가 작을수록 그 효과가 더 커진다는 것을 알 수 있다.

표 1. 각 클래스에 각각 1,000장, 100장, 75장의 훈련 이미지를 활용했을 때의 F1 점수와 테스트 정확도에 대한 비교.

Table1. Comparison of F1 score and test accuracy for 1000, 100, 75 training images for each class.

	비교지표	[1000]	[100]	[75]
w/ x^*	Test accuracy	0.8850	0.8150	0.7922
	F1 score	0.8942	0.8226	0.7800
$w/o x^*$	Test accuracy	0.8500	0.7850	0.6250
	F1 score	0.8657	0.8053	0.7171

IV. 토 론

본 연구에서는 특권정보를 활용하여 높은 정확도를 보여주는 딥러닝 모델을 학습하였다. 매우 흥미로운 점은 표1에서 제시된 것과 같이 특권 정보를 활용할 경우 특권 정보를 활용하지 않았을 때에 비해 높은 성능을 얻을 수 있으며, 적은 수의 데이터를 가지고도 높은 정확도를 보인다는 점이다. 이것은 특권 정보가 학습의 보편화에 긍정적인 역할을 했다고 할 수 있다. 특히 각 클래스당 75장의 이미지만을 활용한 경우 특권정보의 유무에 따른 정확도의 차이가 더욱 크게 벌어진 것을 볼 수 있는데, 이는 각 클래스당 75장의 이미지를 활용

할 경우 특권 정보가 없을 때는 데이터 수에 따라 급격한 성능 저하가 일어나지만, 특권 정보가 있을 때는 우리가 원하는 부분에 대해 좀 더 학습이 잘 될 수 있어, 적은 수의 샘플 데이터를 가지고 처리했을 때, 특권 정보를 활용한 것이 그렇지 않은 경우보다 상대적으로 더 나은 모델 성능을 보여주었다. 이는 도입부에서 설명한 사람에 대한 학습에서 선생님이 부가적인 설명을 통해 사람으로 하여금 원하는 임무를 더 빠르게 이해할 수 있도록 하는 것과 같다.

그러나 본 연구에도 여러 한계점이 존재한다. 본 연구에서는 폐렴과 정상으로 분류되는 두 가지 클래스에 대한 분류 문제를 해결하려고 시도하였다. 첫째, 여기서 특권 정보로 폐렴 환자와 정상인의 폐만을 지정하였는데, 의학적 지식의 한계로 인해, 질병진단에 더욱 유의미한 부분을 지정하지는 못하였다. 이로 인해 훈련된 모델이 더 유의미한 성능 차이를 내지 못했을 수 있다. 따라서, 후속 연구에서는 질병 진단에 좀 더 초점이 맞춘 특권정보를 제공할 수 있다면 더 적은 데이터로도 더 높은 성능을 보여줄 수 있을 것으로 기대한다. 둘째, 또한, 전문가의 자문을 받을 때의 시간적, 비용적 한계와 유의미한 영역에 대한 편차를 줄이기 위해 모델에 도움이 되는 특권 정보 추출을 자동으로 해줄 수 있는 분할 네트워크(segmentation networks)를 추가하여 전문가의 자문에 기반하여 추출된 영역을 특권 정보로 하는 모델과의 성능을 비교 및 분석하는 것도 또 다른 연구 방향이 될 수 있다. 마지막으로, 본 연구에서 사용한 모델은 VGG-19로 비교적 단순하고 오래된 모델이다. 따라서, 복잡한 최신 딥러닝 알고리즘에 비해 성능이 다소 떨어질 수 있다. 그러나 본 연구는 특권정보로 인한 성능향상(performance gain)을 평가하는 것이 목적이며, 적은 양의 데이터를 사용할 때 특권정보가 성능향상에 크게 기여함을 보이는 것이 목적으로, 다른 딥러닝 알고리즘도 충분히 사용가능하다.

V. 결 론

본 연구에서는 컴퓨터 비전 분야의 이미지 분류 문제에 많이 활용되는 LUPI 프레임워크를 폐렴과 정상인의 분류문제에 적용했다. 특권 정보를 두 집단의 폐에 초점이 맞춰진 이미지로 제공하였으며, 이는 학습할 모델로 하여금 우리가 원하는 방향으로 학습이 집중될 수 있도록 보조적인 역할을 해준다. 이와 비슷한 역할을 하는 기존의 다중-임무 학습방

식이나, 증류(distillation)와 같은 학습방식을 선택하지 않고 가우시안 드롭아웃(Gaussian Dropout)과 리파라미터라이제이션(reparameterization), 그리고 정보 병목을 통해 직관적으로 학습에 활용될 수 있도록 하는 방법을 활용했다. 우리의 실험은 특권 정보를 활용할 때 더 높은 정량적 성능뿐만 아니라 해석 가능한 결론을 내릴 수 있는 모델을 만들 수 있다는 점을 제시하였다. 향후 의학 분야에서도 전문적인 특권정보를 모델 훈련에 포함함으로써 딥러닝 모델이 우리가 원하는 임무에 최적화시킬 수 있으며, 해석가능성을 향상시킬 수 있음으로 보였다.

REFERENCES

- [1] J. Rathod, V. Wazhmode, A. Sodha, and P. Bhavathankar, Diagnosis of skin diseases using Convolutional Neural Networks, 2018 Second International Conference on Electronics, Communication and Aerospace Technology (ICECA), pp. 1048-1051, IEEE, Coimbatore, TamilNadu, March 2018.
- [2] Shen, L., Margolies, L. R., Rothstein, J. H., Fluder, E., McBride, R., & Sieh, W. Deep learning to improve breast cancer detection on screening mammography. Scientific reports, 9(1), 1-12. 2019.
- [3] Mohsen, H., El-Dahshan, E. S. A., El-Horbaty, E. S. M., & Salem, A. B. M. Classification using deep learning neural networks for brain tumors. Future Computing and Informatics Journal, 3(1), 68-71, 2018.
- [4] Ari, A., & Hanbay, D. Deep learning based brain tumor classification and detection system. Turkish Journal of Electrical Engineering & Computer Sciences, 26(5), 2275-2286, 2018.
- [5] Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. Imagenet: A large-scale hierarchical image database. In 2009 IEEE conference on computer vision and pattern recognition (pp. 248-255). Ieee, Miami, FL, June 2009.
- [6] Lambert, J., Sener, O., & Savarese, S. Deep learning under privileged information using heteroscedastic dropout. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 8886-8895), Salt Lake City, Utah, June 2018.
- [7] Vapnik, V., & Vashist, A. A new learning paradigm: Learning using privileged information. Neural networks, 22(5-6), 544-557, 2009.
- [8] Sharmanska, V., Quadrianto, N., & Lampert, C. H. Learning to transfer privileged information. arXiv preprint arXiv:1410.0389, 2014.
- [9] Feyereisl, J., & Aickelin, U. Privileged information for data clustering. Information Sciences, 194, 4-23,

- 2012.
- [10] Fouad, S., Tino, P., Raychaudhury, S., & Schneider, P. Incorporating privileged information through metric learning. *IEEE transactions on neural networks and learning systems*, 24(7), 1086-1098, 2013.
- [11] Hinton, G., Vinyals, O., & Dean, J. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- [12] Lopez-Paz, D., Bottou, L., Scholkopf, B., & Vapnik, V. Unifying distillation and privileged information. *arXiv preprint arXiv:1511.03643*, 2015.
- [13] Hoffman, J., Gupta, S., & Darrell, T. Learning with side information through modality hallucination. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 826-834), Las Vegas, Nevada, June 2016.
- [14] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research*, 15(1), 1929-1958, 2014.
- [15] Tishby, N., Pereira, F. C., & Bialek, W. The information bottleneck method. *arXiv preprint physics/0004057*, 2000.
- [16] Achille, A., & Soatto, S. Information dropout: Learning optimal representations through noisy computation. *IEEE transactions on pattern analysis and machine intelligence*, 40(12), 2897-2905, 2018.
- [17] Simonyan, K., & Zisserman, A. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- [18] Kingma, D. P., Salimans, T., & Welling, M. Variational dropout and the local reparameterization trick. In *Advances in neural information processing systems* (pp. 2575-2583), 2015.
- [19] Da, K. A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [20] He, K., Zhang, X., Ren, S., & Sun, J. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778), Las Vegas, Nevada, June 2016.
- [21] Kermany, D. S., Goldbaum, M., Cai, W., Valentim, C. C., Liang, H., Baxter, S. L., ... & Dong, J. Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell*, 172(5), 1122-1131, 2018.

저 자 소 개



고 명 섭(정회원)
2016년 고려대학교 전자 및 정보
공학과 학사 졸업.
2018년 고려대학교 전자정보공학
과 석사 졸업.
<주관심분야: 기계 학습, 보안, 컴
퓨터 비전>



정 병 창(비회원)
2019년 고려대학교 전자 및 정보
공학과 학사 졸업.
<주관심분야: 인공지능, 뇌영상분석>



김 대 겹(비회원)
2017년 고려대학교 전자 및 정보공
학과 학사 졸업.
<주관심분야: 인공지능, 뇌영상분석,
네트워크분석>



한 철(정회원)
2002년 서울대학교 전기공학부 학사
졸업.
2005년 University of Southern
California 석사 졸업.
2009년 University of Southern
California 박사 졸업.
<주관심분야: 인공지능, 의료영상처리, 뇌과학>